


Analyse différentielle de l'abondance des protéines : tests d'égalité des moyennes

Andreas Zanzoni (orcid.org/0000-0002-4818-6161)

Jacques van Helden (orcid.org/0000-0002-8799-8584)

Lou Bergogne (orcid.org/0009-0004-9409-0154)

Choix d'un test de comparaison de moyennes




Moyennes marginales par type de tissu

Nous avons calculé la moyenne marginale de l'abondance ($\log_2(\text{LFQ})$) dans les échantillons des deux types de tissu: foie (liver) et hépatocarcinomes cellulaires (HCC).

Chaque point représente une protéine.

Observations


- Tendence générale : les points s'alignent plus ou moins sur la médiane
- On observe cependant des points qui s'en écartent. A priori ce sont ces points-là qui nous intéressent, mais il faudrait relativiser la différence par rapport à la dispersion (écart-type) entre échantillons d'un même type.



Le nuage de points représente la comparaison des variances par protéine entre biopsies de foie (abscisse) et hépatocarcinomes cellulaires (ordonnée)

Observations

- Tendance générale : sont très concentrés dans un carré allant de (0,0) à (2,2).
- En dehors de ce carré, on observe une grande dispersion des points.
- Les points semblent répartis de façon inégale entre les deux côtés de la médiane : une grande majorité de points semble avoir une variance supérieure dans les HCC que dans le foie.




Écarts-types marginaux par type de tissu

Le nuage de points représente la comparaison des écarts-types par protéine entre biopsies de foie (abscisse) et hépatocarcinomes cellulaires (ordonnée)



Observations

- Tendance générale : les points suivent une direction oblique, mais elle semble décalée par rapport à la médiane.
- On observe cependant des points qui s'en écartent. A priori ce sont ces points-là qui nous intéressent, mais il faudrait relativiser la différence par rapport à la dispersion (écart-type) entre échantillons d'un même type.



Comparaison moyenne - écart-type

- L'écart-type montre de grosses différences selon les échantillons.
- Il n'y a pas de relation évidente entre la moyenne et l'écart-type : les écarts-types les plus élevés semblent associés à des moyennes plutôt faibles.



Choix du test pour les données protéomiques de Canale, 2023

Les données sont-elles normales ?

- Nous disposons d'une trentaine d'échantillons biologiques par groupe (max: 35 Liver + 34 HCC, sachant que il y a un certain nombre d'observations manquantes par protéine).
- Idéalement, on devrait faire un test de normalité pour chaque protéine. Cependant, avec une trentaine d'échantillons, le test de Shapiro manque de puissance.


Grands échantillons ?

- En dépit de l'incertitude concernant la normalité, avec une trentaine d'individus par groupe, on peut se rabattre sur un test paramétrique, en vertu du théorème central limite.

Variances égales ?

- Nous pourrions effectuer un test d'égalité de variances, mais ici aussi la taille des échantillons serait limitante.
- Du point de vue biologique, il est raisonnable de supposer que le cancer affecte différemment les cellules de chaque patient et donc qu'on ait une variance plus élevée dans les cellules HCC que dans le foie non-cancéreux.
- Ceci correspond également à notre observation précédente : la variance et l'écart-type semblent souvent plus élevés pour le groupe HCC que pour le groupe Liver.

→ **test de Welch**



Test d'égalité de moyenne




Modalités

- Bilatéral : $H_0: \mu_1 = \mu_2$ $H_1: \mu_1 \neq \mu_2$
- Unilatéral :
 - A gauche : $H_0: \mu_1 \geq \mu_2$ $H_1: \mu_1 < \mu_2$
 - A droite : $H_0: \mu_1 \leq \mu_2$ $H_1: \mu_1 > \mu_2$

Principe du test

- Estimer la différence d entre les moyennes des deux populations μ_1 and μ_2
- Relativiser cette différence par rapport à son erreur standard
- Comparer cette différence avec la distribution théorique
- Décision concernant l'hypothèse nulle
 - Rejet : $R(H_0)$
 - Acceptation, ou plus précisément non-rejet : $A(H_0)$
- Configurations
 - Test unilatéral à gauche: $R(H_0)$ si $t_{obs} \leq t_a$
 - Test unilatéral à droite: $R(H_0)$ si $t_{obs} \geq t_{(1-a)}$
 - Test bilatéral: $R(H_0)$ si $t_{obs} \geq t_{(1-a/2)}$

$$t_{obs} = \frac{\hat{\mu}_1 - \hat{\mu}_2}{\hat{\sigma}_{\mu_1 - \mu_2}} = \frac{\hat{\mu}_1 - \hat{\mu}_2}{\sqrt{\frac{\hat{\sigma}_1^2}{n_1} + \frac{\hat{\sigma}_2^2}{n_2}}}$$



Calcul de la statistique t observée t_{obs}

Les variances des deux populations sont généralement inconnues → il faut également les estimer




- La variance d'une différence est la somme des variances : $\sigma^2_{\mu_1 - \mu_2} = \sigma^2_{\mu_1} + \sigma^2_{\mu_2}$
- La formule pour l'estimation est différente selon qu'on considère que les deux variances sont égales (**hypothèse d'homoscédasticité**) ou pas (**hypothèse d'hétéroscédasticité**) → voir diapo suivante

$$t_{obs} = \frac{\hat{\mu}_1 - \hat{\mu}_2}{\hat{\sigma}_{\mu_1 - \mu_2}} = \frac{\hat{\mu}_1 - \hat{\mu}_2}{\sqrt{\frac{\hat{\sigma}_1^2}{n_1} + \frac{\hat{\sigma}_2^2}{n_2}}}$$

	Hypothèse de travail : égalité de variances (homoscédasticité) → test de Student	Hypothèse de travail : inégalité des variances (hétéroscédasticité) → test de Welch
Statistique t observée (t_{obs})	$t_S = \frac{\hat{\delta}}{\hat{\sigma}_{\delta}} = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2} \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$	$t_W = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1 - 1} + \frac{s_2^2}{n_2 - 1}}}$
Degrés de liberté	$\nu_S = n_1 + n_2 - 2$	$\nu_W = \frac{\left(\frac{s_1^2}{n_1 - 1} + \frac{s_2^2}{n_2 - 1} \right)^2}{\frac{s_1^4}{(n_1 - 1)^3} + \frac{s_2^4}{(n_2 - 1)^3}}$

Distribution de Student

- Une famille de courbes caractérisées par 1 paramètre : le nombre de **degrés de liberté** (df)
- La forme varie selon df
- Converge vers une normale quand $df \rightarrow \infty$



Test bilatéral : décision d'acceptation / rejet de l'hypothèse nulle

Hypothèse de travail : égalité de variances
(homoscédasticité) → test de Student

$$t_S = \frac{\hat{\delta}}{\hat{\sigma}_\delta} = \frac{\bar{x}_2 - \bar{x}_1}{\sqrt{\frac{n_1 s_1^2 + n_2 s_2^2}{n_1 + n_2 - 2} \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

Degrés de liberté pour le test de Student

$$\nu_S = n_1 + n_2 - 2$$


Hypothèse de travail : inégalité des variances
(hétéroscédasticité) → test de Welch

$$t_W = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$


Degrés de liberté pour le test de Welch

$$\nu_W = \frac{\left(\frac{s_1^2}{n_1 - 1} + \frac{s_2^2}{n_2 - 1} \right)^2}{\frac{s_1^4}{(n_1 - 1)^3} + \frac{s_2^4}{(n_2 - 1)^3}}$$

Student density, df=10



Student Cumulative Distribution Function, df = 10



Test bilatéral : décision d'acceptation / rejet de l'hypothèse nulle

t_{obs} dans la région rouge $\rightarrow R(H_0)$

t_{obs} dans la région verte $\rightarrow A(H_0)$

Hypothèse de travail : égalité de variances
(homoscédasticité) $\rightarrow$ test de Student

$$t_S = \frac{\hat{\delta}}{\hat{\sigma}_\delta} = \frac{\bar{x}_2 - \bar{x}_1}{\sqrt{\frac{n_1 s_1^2 + n_2 s_2^2}{n_1 + n_2 - 2} \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

Degrés de liberté pour la distribution t



$$\nu_S = n_1 + n_2 - 2$$

Hypothèse de travail : inégalité des variances
(hétéroscédasticité) $\rightarrow$ test de Welch

$$t_W = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$


Degrés de liberté pour la distribution t

$$\nu_W = \frac{\left(\frac{s_1^2}{n_1 - 1} + \frac{s_2^2}{n_2 - 1} \right)^2}{\frac{s_1^4}{(n_1 - 1)^3} + \frac{s_2^4}{(n_2 - 1)^3}}$$




MA plot

- A = moyenne entre les niveaux d'abondance des deux conditions ("average")
- M = différence entre les deux conditions ("minus")
 - Comme les mesures $\log_2(\text{LFQ})$ sont des logarithmes, la différence correspond au "log2-fold change" (**log2FC**)
 $\log_2(\text{HCC}) - \log_2(\text{liver}) = \log_2(\text{HCC} / \text{liver})$
 - On appelle "fold-change" le rapport $\text{HCC} / \text{liver}$
 $\log_2\text{FC} = 2 \rightarrow \text{HCC} / \text{liver} = 4$
 $\log_2\text{FC} = -2 \rightarrow \text{liver} / \text{HCC} = 4$
- Sur ce graphique, nous avons marqué arbitrairement
 - en **vert** les protéines ayant un $\log_2\text{FC} \geq 2$
 - en **rouge** les protéines ayant un $\log_2\text{FC} \leq -2$



Volcano plot

- Abscisse : **taille d'effet (effect size)** :
 $d = \log_2(HCC) - \log_2(liver) = \log_2(HCC/liver)$
- Ordonnée : **$-\log_{10}(P)$** où P est la p-valeur
 $d = \log_2(HCC) - \log_2(liver) = \log_2(HCC/liver)$
- Les points les plus élevés sont les plus significatifs.
- Nous avons placé des seuils arbitraires sur la taille d'effet et sur le $-\log_{10}(P)$.



Exercices

Échantillonnage et estimation

On a testé l'effet un médicament sur des souris, avec 6 souris traitées (test) et 6 non-traitées (contrôle). Pour le contrôle, une des 6 mesures a échoué, on a donc une valeur non définie (NA).

Dans cette configuration, définissez les concepts d'échantillons et de populations.

Comment estimez-vous les paramètres de populations à partir de ces données ?

- Moyenne
- Écart-type

Indiquez les formules avec les symboles, et ensuite avec les valeurs numériques. Vous ne devez pas calculer le résultat numérique.

i	Measurements	
	test	control
1	7	10
2	9	11
3	8	NA
4	11	12
5	14	13
6	13	15

Test d'égalité de moyennes

On a testé l'effet un médicament sur des souris, avec 6 souris traitées (test) et 6 non-traitées (contrôle). Pour le contrôle, une des 6 mesures a échoué, on a donc une valeur non définie (NA).

On effectue un test paramétrique d'égalité des moyennes.

- Quelles sont vos hypothèses de travail ?
- Vous semblent-elles justifiées ?
- Comment calculez-vous la statistique de test ? Indiquez la formule avec les symboles, puis la formule avec les valeurs numériques.
- Calculez le résultat
- Indiquez le risque de première espèce associé à ce résultat
- Quelle décision prenez-vous ?

	Measurements	
i	test	control
1	7	10
2	9	11
3	8	NA
4	11	12
5	14	13
6	13	15
Sum	62	61
n	6	5
mean	10.33	12.20
sd	2.80	1.92

	Sorted values		Ranks	
i	test	control	test	control
1	7.00		1.00	
2	8.00		2.00	
3	9.00		3.00	
4		10.00		4.00
5	11.00	11.00	5.50	5.50
6		12.00		7.00
7	13.00	13.00	8.50	8.50
8	14.00		10.00	
9		15.00		11.00
Sum			30.00	36.00
n	6	5	6	5
Mean			5	7.2

Mesure empirique des taux d'erreurs et de la puissance pour le test de comparaison de moyennes

Cadre général d'un test statistique

Lors de la mise en oeuvre d'un test statistique, deux situations sont possibles

- L'hypothèse nulle (H_0) est vraie. On dit aussi "nous sommes sous H_0 ".
- L'hypothèse nulle (H_0) est fausse, nous sommes sous hypothèse alternative (H_1)

Suite à la réalisation d'un test statistique, 2 décisions sont possibles

- Rejet de l'hypothèse nulle : $R(H_0)$
- Non-rejet (acceptation temporaire) de l'hypothèse nulle : $A(H_0)$

Puissance d'un test

- La **puissance d'un test** est la probabilité de rejeter l'hypothèse nulle quand elle est fausse

$$P(R(H_0) \mid H_1) = 1 - \beta$$

où le symbole $\mid$ signifie "étant donné que".

La puissance d'un test dépend fortement de

- La taille d'effet (à quel point les données s'écartent de ce qu'on attendrait sous hypothèse nulle)
- La taille de l'échantillon
- Le seuil qu'on a choisi pour la p-valeur (α)

	H0	H1
R(H0)	Erreur de type I Risque alpha (α)	Rejet justifié
A(H0)	Acceptation justifiée	Erreur de type II Risque bêta (β)

Evaluation empirique de la puissance du test t de Student

Approche : simulations numériques "Monte Carlo"

- **Tirages aléatoires** dans une distribution normale
 - Sous H_0 : $\mu_1 = \mu_2 = 7$, $\delta = \mu_1 - \mu_2 = 0$
 - Sous H_1 : $\mu_1 = 6$; $\mu_2 = 8$, $\delta = \mu_1 - \mu_2 = 2$
 - $\sigma_1 = \sigma_2 = 1$; $n_1 = n_2 = 10$
- Pour chaque tirage, on fait un test t de Student et on récupère la p-valeur.
- On fixe un **seuil de p-valeur** $\alpha = 5\%$.
- Le test est **déclaré positif** si $P_{val} \leq \alpha$, sinon négatif

On répète l'expérience $r = 1000$ fois et on dénombre

- Faux Positifs (**FP**) : tests déclarés positifs sous H_0
- Vrais négatifs (**TN**) : tests déclarés négatifs sous H_0
- Faux négatifs (**FN**) : tests déclarés négatifs sous H_1
- Vrais positifs (**TP**) : tests déclarés positifs sous H_1

On dérive les statistiques suivantes

- **False Positive Rate (FPR)** :
proportion de tests **déclarés positifs** sous H_0
- **True Positive Rate (TPR) = sensitivity = recall** :
proportion de tests **déclarés positifs** sous H_1

Dans ce cadre-ci, où nous contrôlons les données d'entrée, le but est d'évaluer les performances d'un test statistique. On peut interpréter le TPR comme une estimation "Monte Carlo" de la puissance du test de Student.

	H0	H1
Test déclaré positif	False Positive (FP)	True Positive (TP)
Test déclaré négatif	True Negative (TN)	False Negative (FN)

$$\text{FPR} = \text{FP} / (\text{FP} + \text{TN})$$

$$\text{Sn} = \text{TPR} = \text{TP} / (\text{FN} + \text{TP})$$

FP	TP
TN	FN

FP	TP
TN	FN

Complément d'information : statistiques de classification

On peut également dériver d'autres statistiques informatives à partir des nombres de tests déclarés + ou - sous H_0 ou H_1 .

- Faux Positifs (FP) : tests déclarés positifs sous H_0
- Vrais négatifs (TN) : tests déclarés négatifs sous H_0
- Faux négatifs (FN) : tests déclarés négatifs sous H_1
- Vrais positifs (TP) : tests déclarés positifs sous H_1

On dérive les statistiques suivantes

- **False Positive Rate (FPR)** :
proportion de tests déclarés positifs sous H_0
- **True Negative Rate (TNR) = specificity** :
proportion de tests déclarés négatifs sous H_0
- **False Negative Rate (FNR)** :
proportion de tests déclarés négatifs sous H_1
- **True Positive Rate (TPR) = sensitivity = recall** :
proportion de tests déclarés positifs sous H_1
- **Positive Predictive Value (PPV)** :
proportion de tests sous H_1 parmi ceux déclarés positifs
- **Negative Predictive Value (NPV)** :
proportion de tests sous H_0 parmi ceux déclarés négatifs

Ces statistiques sont fréquemment utilisées en analyse des données biologiques et médicales.

	H_0	H_1
Test déclaré positif	False Positive (FP)	True Positive (TP)
Test déclaré négatif	True Negative (TN)	False Negative (FN)

$$\text{FPR} = \text{FP} / (\text{TN} + \text{FP})$$

$$\text{Sp} = \text{TNR} = \text{TN} / (\text{TN} + \text{FP})$$

$$\text{FNR} = \text{FN} / (\text{TP} + \text{FN})$$

$$\text{Sn} = \text{TPR} = \text{TP} / (\text{TP} + \text{FN})$$

$$\text{PPV} = \text{TP} / (\text{TP} + \text{FP})$$

$$\text{NPV} = \text{TN} / (\text{TN} + \text{FN})$$

FP	TP
TN	FN

FP	TP
TN	FN

FP	TP
TN	FN

FP	TP
TN	FN

FP	TP
TN	FN

FP	TP
TN	FN

Evaluation empirique de la puissance du test t de Student



Sous H_0

- $\alpha=5\% \rightarrow$ parmi les $r=10.000$ répétitions on s'attend a priori à avoir $\sim \alpha \cdot R = 500$ FP.
- Dans la simulation, on observe effectivement 502* FP $\rightarrow$
 $FPR = 502/10.000 = 5.02\%$
(rectangle rouge sur l'histogramme).
- Par définition, sous H_0 les P-valeurs sont réparties de façon uniforme entre 0 et 1.
- Ceci correspond à la distribution des 10.000 P-valeurs obtenues.
- Les statistiques t observées suivent une distribution de Student centrée sur 0.

Sous H_1

- Dans les conditions de cette simulation, nous obtenons 5547 vrais positifs $\rightarrow$
 $Sn = TPR = 55,47\%$
- Ceci fournit une estimation empirique de la puissance du test.


* Les nombres fluctuent d'une simulation à l'autre.




	H0	H1
Test déclaré positif	False Positive (FP)	True Positive (TP)
Test déclaré négatif	True Negative (TN)	False Negative (FN)

Impact de la différence de moyennes sur la puissance du test


Impact of mean difference on the t statistics



Impact of mean difference on the Student P-value



Impact of effect size on sensitivity



Symboles et formules	Description
μ_1, μ_2	Moyennes respectives des populations 1 et 2.
σ_1, σ_2	Ecart-types respectifs des populations 1 and 2.
N_1, N_2	Tailles (nombre d'individus) des populations 1 et 2.
n_1, n_2	Effectifs (nombre d'individus) des échantillons prélevés sur les populations 1 et 2.
$\bar{x}_1, \bar{x}_2$	Moyennes d'échantillons.
$\delta = \mu_2 - \mu_1$	Différence entre les moyennes des populations.
$d = \hat{\delta} = \hat{\mu}_2 - \hat{\mu}_1 = \bar{x}_2 - \bar{x}_1$	d = Taille d'effet: dans un test de comparaison de moyennes, il s'agit de la différence entre les moyennes d'échantillons, utilisée comme estimateur de δ .
s_1^2, s_2^2	Variances mesurées sur les échantillons.
$\hat{\sigma}_p = \sqrt{\frac{n_1 s_1^2 + n_2 s_2^2}{n_1 + n_2 - 2}}$	Ecart-type groupé (<i>pooled standard deviation</i>), utilisé comme estimateur de l'écart-type commun des deux populations, en supposant leurs variances égales (hypothèse de travail d'homoscédasticité).
$\hat{\sigma}_\delta = \hat{\sigma}_p \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}$	Erreur standard sur la différence entre moyennes, en supposant que les populations ont la même variance (test de Student).
$t_S = \frac{\hat{\delta}}{\hat{\sigma}_\delta} = \frac{\bar{x}_2 - \bar{x}_1}{\sqrt{\frac{n_1 s_1^2 + n_2 s_2^2}{n_1 + n_2 - 2} \left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$	statistique <i>t</i> de Student
$t_W = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$	statistique <i>t</i> de Welch

