

Test d'ajustement

Andreas Zanzoni (orcid.org/0000-0002-4818-6161)

Jacques van Helden (orcid.org/0000-0002-8799-8584)

Lou Bergogne (orcid.org/0009-0004-9409-0154)


Test d'ajustement

Test statistique qui permet de vérifier si un échantillon observé est compatible avec un modèle théorique donné.

Modèle théorique = loi de probabilité




Une épreuve, ou test, de normalité est un cas particulier de test d'ajustement qui sert à vérifier si un échantillon suit la loi normale.

Avant d'appliquer un test de normalité, il est toujours préférable d'examiner les données (évaluation visuelle).









Evaluation visuelle: les histogrammes

Selon vous, parmi les distributions représentées ci-dessous, laquelle ou lesquelles pourraient suivre une loi normale ?





Evaluation visuelle: les histogrammes



Evaluation visuelle: les histogrammes

Un simple évaluation visuelle des distributions peut être trompeuse




Evaluation visuelle: les Q-Q plots

Un diagramme quantile-quantile, ou Q-Q plot, permet d'évaluer graphiquement l'ajustement d'un échantillon à modèle théorique.

Quantile = valeur qui sépare un échantillon en intervalles de la même taille ou probabilité.

Dans un Q-Q plot on compare la position des quantiles de l'échantillon observés avec leur position dans la population théorique.

Si les points resultants s'alignent (à peu près) sur une ligne droite, on peut supposer que l'ajustement est pertinent.



Evaluation visuelle: les Q-Q plots

Quantile = valeur qui sépare un échantillon en intervalles de la même taille ou probabilité.


Modèle théorique = loi de probabilité

Cas particulier: les **quartiles**: l'échantillon est divisé en 4 intervalles par 3 quartiles ($Q1$, $Q2$, $Q3$).







Le deuxième quartile, $Q2$, est la **médiane**.

L'écart entre le troisième quartile $Q3$ et le premier quartile $Q1$ est défini comme l'écart interquartile (IQR , *Interquartile Range*). C'est une mesure de la dispersion.

Les quartiles peuvent être utilisés pour représenter graphiquement des paramètres de position (ex., la médiane), de dispersion (IQR) et l'asymétrie d'un échantillon (ex positions relatives de $Q1$ et $Q3$ par rapport à la médiane sur un diagramme en boîte à moustaches ou *boxplot*).



Selon vous, parmi les distributions représentées ci-dessous, laquelle ou lesquelles pourraient suivre une loi normale ?



Soit une variable **X** avec une moyenne $\bar{X}$, avec **N** valeurs classées de la plus petite à la plus grande valeur (de 1...i...à N) .

Soit le score **W**.

La fonction **f** attendue d'un échantillon issu d'une distribution normale.

Le dénominateur étant la somme des carrés des écarts à la moyenne.

Un score proche de 1 indique une distribution normale.

L'hypothèse nulle H_0 : la distribution observée suit une loi normale.

$$W = \frac{(\sum f(X_i))^2}{\sum (X_i - \bar{X})^2}$$

Énoncé exercice 2 : Association entre variation allélique et l'expression génique

L'activité d'un promoteur a été testée grâce à une expérience de "luciferase assay".


L'expérience a mesuré le signal luciférase de l'allèle de type sauvage (*WT* pour *wild-type*) et celui d'un allèle mutant.

Vérifier la normalité des données avec le Q-Q plot et le test de Shapiro-Wilk.

Évaluer si les allèles de types respectifs sauvage et mutant diffèrent au niveau de leur signal luciférase moyen, en utilisant un test *t*.

Formuler l'hypothèse nulle H_0 .

Y a-t-il un lien entre la variation allélique et l'expression génique ?



<https://www.activemotif.com/>

Énoncé exercice 3 : Analyse différentielle d'abondance de deux protéines

Nous avons sélectionné deux protéines identifiées dans l'expérience décrite dans l'article de Canale *et al.* (2023).


- *Procollagen-lysine,2-oxoglutarate 5-dioxygenase 1* codée par le gène **PLOD1**.
- *Sterol O-acyltransferase 1* codée par le gène **SOAT1**.

Nous avons à disposition les données d'abondance dans les échantillons de carcinome hépatique (*HCC*) et dans les échantillons prélevés dans les zones non-cancéreuses du foie des mêmes patients (*liver*).

Pour chaque protéine,

- vérifiez la normalité des données (*HCC* et *liver*) avec le Q-Q plot et le test de Shapiro-Wilk.
- évaluez si l'abondance diffère entre les échantillons *HCC* et les échantillons *liver* en utilisant un test *t*.

Pour chaque test, formulez l'hypothèse nulle, effectuez le test, et tirez vos conclusions.



Canale, F. P. et al. Proteomics of immune cells from liver tumors reveals immunotherapy targets. *Cell Genomics* 3, 100331 (2023). doi.org/10.1016/j.xgen.2023.100331

Puissance d'un test de Shapiro-Wilk

Cadre général d'un test statistique

Lors de la mise en oeuvre d'un test statistique, deux situations sont possibles

- L'hypothèse nulle (H_0) est vraie. On dit aussi "nous sommes sous H_0 ".
- L'hypothèse nulle (H_0) est fausse, nous sommes sous hypothèse alternative (H_1)

Suite à la réalisation d'un test statistique, 2 décisions sont possibles

- Rejet de l'hypothèse nulle : $R(H_0)$
- Non-rejet (acceptation temporaire) de l'hypothèse nulle: $A(H_0)$

Puissance d'un test

- Taux de rejet de l'hypothèse nulle quand elle est fausse
 $P(R(H_0) | H_1) = 1 - \beta$
où le symbole $|$ signifie "étant donné que".

La puissance d'un test dépend fortement de

- La taille d'effet (à quel point les données s'écartent-elles de ce qu'on attendrait sous hypothèse nulle)
- La taille de l'échantillon

	H_0	H_1
$R(H_0)$	Erreur de type I Risque alpha	Rejet justifié
$A(H_0)$	Acceptation justifiée	Erreur de type II Risque beta

Evaluation empirique de la puissance du test de Shapiro

Approche : simulations numériques









- Tirages aléatoires
 - Sous H_0 : dans distribution normale avec `rnorm()`
 - Sous H_1 : dans distribution uniforme avec `runif()`
- Pour chaque tirage, on fait un test de Shapiro-Wilk et on récupère la p-valeur
- On répète l'expérience $r = 1000$ fois pour chacune des deux distributions
- On dessine quelques Q-Q plots pour avoir une idée de leur forme
- On choisit un seuil de p-valeur de 5%. On fixe ainsi la valeur du risque d'erreur de premier type (α).
- On calcule le **taux de faux-négatifs**: parmi les 1000 essais sous H_1 , quelle est la proportion de résultats **déclarés positifs** (autrement dit, dont la P-valeur est inférieure au seuil α qu'on a défini).
- Ce taux de faux négatifs empirique fournit une estimation du risque de faux négatifs β .

	H_0	H_1
$R(H_0)$	Erreur de type I Risque alpha	Rejet justifié
$A(H_0)$	Acceptation justifiée	Erreur de type II Risque beta









FPR =

Test empirique du test de Shapiro : rnorm() versus runif() avec n = 10









Tailles d'échantillon délibérément trop faibles.











Test empirique du test de Shapiro : rnorm() versus runif() avec n = 25



Test empirique du test de Shapiro : rnorm() versus runif() avec n = 50



Test empirique du test de Shapiro : rnorm() versus runif() avec n = 75



Test empirique du test de Shapiro : rnorm() versus runif() avec $n = 100$

